

# Сравнение локальных моделей

Бенчмарк документов | run candidate-benchmark-2026-10-04-v1 | 25 синтетических сценариев

**Победитель: Qwen2.5 3B Instruct - 16/25 (64.0%). Второй сохранённый вариант: LFM2.5 1.2B Instruct - 10/25 (40.0%). Второе место рейтинга; компактный вариант в пределах 10 п.п. не найден.**

Проверка интеграции Harness выявила неверный фактический ответ и нестабильный цикл инструмента. Лидер сравнения выбран для локального исследования, не для готового документного продукта. Подробности в последнем разделе.

## Краткий вывод

Ранжирование основано на полном наборе синтетических случаев. Сначала учитывается доля пройденных случаев, затем доля нативного планирования инструментов, меньший прирост общей VRAM и меньшая медианная задержка. Второй вариант выбирается как самый компактный меньший файл в пределах 10 процентных пунктов от победителя; если такого нет, используется второе место общего рейтинга.

## Ограничения интерпретации

Промпты и документы синтетические; здесь не использовались пользовательские документы, не запускались DOCX-инструменты и не выполнялось дообучение. VRAM отражает использование всей видеокарты Windows и других процессов, а не изолированную память одного сервера. Лимит 384 выходных токена может обрезать reasoning-ответы. Результат показывает пригодность к этому корпусу и конфигурации, а не универсальное превосходство модели.


| Показатель       | Результат                                            |
|------------------|------------------------------------------------------|
| Победитель       | Qwen2.5 3B Instruct                                  |
| Второй вариант   | LFM2.5 1.2B Instruct                                 |
| Полный проход    | 25 случаев на модель; неполные отчёты не ранжируются |
| Ограничение VRAM | 5 500 MiB общей памяти GPU                           |
| Формат           | GGUF Q4_K_M; SHA-256 указан в приложении             |

Основные результаты

| Модель               | Пройдено | Медиана | Пик всего | GGUF     |
|----------------------|----------|---------|-----------|----------|
| Qwen2.5 3B Instruct  | 16/25    | 717 ms  | 2161 MiB  | 1.80 GiB |
| LFM2.5 1.2B Instruct | 10/25    | 307 ms  | 905 MiB   | 0.68 GiB |
| LFM2.5 2.6B          | 4/25     | 4124 ms | 1827 MiB  | 1.56 GiB |
| Qwen2.5 Coder 3B     | 3/25     | 912 ms  | 2161 MiB  | 1.80 GiB |
| Qwen2.5 Coder 1.5B   | 1/25     | 517 ms  | 1209 MiB  | 0.92 GiB |
| GPT-2 XL             | 0/25     | 4686 ms | 1545 MiB  | 1.10 GiB |

# Качество по задачам

Доля пройденных случаев и распределение ошибок по категориям. Числитель - cases с grade.passed=true; частичные диагностические баллы не считаются.



## Тепловая карта: пройдено / всего

|                      | Точное редактирование | Строгий JSON | Таблицы | Уточнение без правки | Вызов инструмента | Ответ после tools |
|----------------------|-----------------------|--------------|---------|----------------------|-------------------|-------------------|
| Qwen2.5 3B Instruct  | 6/6                   | 3/4          | 1/2     | 3/5                  | 3/4               | 0/4               |
| LFM2.5 1.2B Instruct | 3/6                   | 2/4          | 0/2     | 1/5                  | 2/4               | 2/4               |
| LFM2.5 2.6B          | 0/6                   | 0/4          | 0/2     | 0/5                  | 1/4               | 3/4               |
| Qwen2.5 Coder 3B     | 0/6                   | 0/4          | 0/2     | 1/5                  | 0/4               | 2/4               |
| Qwen2.5 Coder 1.5B   | 0/6                   | 0/4          | 0/2     | 0/5                  | 0/4               | 1/4               |
| GPT-2 XL             | 0/6                   | 0/4          | 0/2     | 0/5                  | 0/4               | 0/4               |

## Инструменты, JSON и ошибки данных

Отдельно показаны нативные вызовы указанных инструментов, извлечение строгого JSON и структурирование табличных данных. Ни один из сценариев не изменяет реальный файл. Разделение ниже основано на grade checks; типы сбоев могут пересекаться.

### Категорийные проходы

| Модель               | Нативный вызов | Строгий JSON | Табличные данные | Сбои результата* |
|----------------------|----------------|--------------|------------------|------------------|
| Qwen2.5 3B Instruct  | 3/4            | 3/4          | 1/2              | 0                |
| LFM2.5 1.2B Instruct | 2/4            | 2/4          | 0/2              | 0                |
| LFM2.5 2.6B          | 1/4            | 0/4          | 0/2              | 0                |
| Qwen2.5 Coder 3B     | 0/4            | 0/4          | 0/2              | 0                |
| Qwen2.5 Coder 1.5B   | 0/4            | 0/4          | 0/2              | 0                |
| GPT-2 XL             | 0/4            | 0/4          | 0/2              | 0                |

### Ошибки по случаям

Qwen2.5 3B Instruct: Таблицы: 1, Строгий JSON: 1, Уточнение без правки: 2, Вызов инструмента: 1, Ответ по результату инструмента: 4.

LFM2.5 1.2B Instruct: Точное редактирование: 3, Строгий JSON: 2, Таблицы: 2, Уточнение без правки: 4, Вызов инструмента: 2, Ответ по результату инструмента: 2.

LFM2.5 2.6B: Точное редактирование: 6, Строгий JSON: 4, Таблицы: 2, Уточнение без правки: 5, Вызов инструмента: 3, Ответ по результату инструмента: 1.

Qwen2.5 Coder 3B: Точное редактирование: 6, Строгий JSON: 4, Таблицы: 2, Уточнение без правки: 4, Вызов инструмента: 4, Ответ по результату инструмента: 2.

Qwen2.5 Coder 1.5B: Точное редактирование: 6, Строгий JSON: 4, Таблицы: 2, Уточнение без правки: 5, Вызов инструмента: 4, Ответ по результату инструмента: 3.

GPT-2 XL: Точное редактирование: 6, Строгий JSON: 4, Таблицы: 2, Уточнение без правки: 5, Вызов инструмента: 4, Ответ по результату инструмента: 4.

### Разделение типов сбоев

| Модель               | Обрезка / сбой | Невалидный JSON | Только формат | Данные / аргументы | Протокол инструмента | Повтор в follow-up |
|----------------------|----------------|-----------------|---------------|--------------------|----------------------|--------------------|
| Qwen2.5 3B Instruct  | 0              | 0               | 0             | 9                  | 0                    | 4                  |
| LFM2.5 1.2B Instruct | 0              | 3               | 0             | 15                 | 1                    | 0                  |
| LFM2.5 2.6B          | 7              | 4               | 13            | 8                  | 3                    | 0                  |
| Qwen2.5 Coder 3B     | 0              | 0               | 11            | 11                 | 4                    | 0                  |
| Qwen2.5 Coder 1.5B   | 0              | 0               | 12            | 12                 | 4                    | 0                  |
| GPT-2 XL             | 25             | 17              | 0             | 24                 | 4                    | 0                  |


Новый вызов инструмента в follow-up после получения результата: Qwen2.5 3B Instruct: 4/4. Это повторный протокольный вызов, а не отсутствие поддержки tools; первичное планирование показано отдельно.

Фиксированный лимит составляет 384 выходных токена. finish\_reason=length выделен как cutoff, а не автоматически как ошибка рассуждения; он может влиять на модели с длинными внутренними ответами. Выводы относятся к данному корпусу и настройкам.


\* Считаются только явные result.error, без вывода скрытых рассуждений. Ошибки качества - это непройденные критерии fixture.

## Память видеокарты

Порог guard - 5 500 MiB общей занятой памяти. Сервер кандидата останавливается при превышении порога; предзапусковая проверка также учитывает размер модели и запас.



## Временные ряды фактических замеров GPU




| Секунды с первого замера |           |            |          |              |                 |
|--------------------------|-----------|------------|----------|--------------|-----------------|
| Модель                   | Пик всего | До запуска | Прирост  | Свободно min | Запас до порога |
| Qwen2.5 3B Instruct      | 2161 MiB  | 0 MiB      | 2161 MiB | 3841 MiB     | 3339 MiB        |
| LFM2.5 1.2B Instruct     | 905 MiB   | 0 MiB      | 905 MiB  | 5097 MiB     | 4595 MiB        |
| LFM2.5 2.6B              | 1827 MiB  | 0 MiB      | 1827 MiB | 4175 MiB     | 3673 MiB        |
| Qwen2.5 Coder 3B         | 2161 MiB  | 0 MiB      | 2161 MiB | 3841 MiB     | 3339 MiB        |
| Qwen2.5 Coder 1.5B       | 1209 MiB  | 0 MiB      | 1209 MiB | 4793 MiB     | 4291 MiB        |
| GPT-2 XL                 | 1545 MiB  | 0 MiB      | 1545 MiB | 4457 MiB     | 3955 MiB        |

Baseline - значение nvidia-smi до старта конкретной модели; оно может включать Windows, дисплей и другие процессы. Peak delta - разница общей занятой памяти относительно этого baseline, не per-process оценка.

Отдельная проверка baseline: сервер Qwen3.5-2B-Q4\_K\_M (qwen3.5-2b, port 8081) остановлен по запросу пользователя; общая занятая память изменилась с 1483 до 0 MiB. Точное время остановки не записано. Поздняя idle-перепроверка 2026-10-03T21:04:13.5455421Z показала 0 MiB used / 6001 MiB free. Эти значения не входят в рейтинг кандидатов.

## Скорость ответа

Медиана и p95 рассчитаны из case latency; tokens/s и суммарная latency взяты из проверенного calculations.json. Latency включает полный HTTP round-trip и зависит от системной нагрузки.



| Модель               | Медиана | 95-й перцентиль | Токенов/с, медиана | Сумма задержек |
|----------------------|---------|-----------------|--------------------|----------------|
| Qwen2.5 3B Instruct  | 717 ms  | 1302 ms         | 66.45              | 18.0 s         |
| LFM2.5 1.2B Instruct | 307 ms  | 579 ms          | 171.42             | 8.6 s          |
| LFM2.5 2.6B          | 4124 ms | 5115 ms         | 77.27              | 100.2 s        |
| Qwen2.5 Coder 3B     | 912 ms  | 2547 ms         | 62.25              | 24.6 s         |
| Qwen2.5 Coder 1.5B   | 517 ms  | 837 ms          | 108.88             | 13.2 s         |
| GPT-2 XL             | 4686 ms | 5009 ms         | 86.61              | 116.6 s        |

### Контекст измерения

Настройки бенчмарка: температура 0, seed 42, один слот, 99 слоёв GPU и максимум 384 выходных токена. Прямой API-бенчмарк использует context из каждого отчёта. Профиль Astra использует контекст 8 192 для сохранения бюджета ответа pi-ai.

При сравнении важны и задержка, и содержательная точность: более быстрый ответ не компенсирует пропуск обязательных данных или неверный формат.

## Размер и оценка параметров

Параметры и байтовые оценки приведены из calculations.json. P - число сохранённых float tensor elements после исключения известных buffer elements; это не гарантированное число уникальных, trainable или shared model parameters. Теоретические оценки не равны фактической VRAM: они не включают KV cache, optimizer/training state или runtime buffers; GGUF также включает метаданные и структуры квантования.

| Модель               | Параметры | Исходные веса | Файлы    | Оценка FP16 | Идеал 4-bit | GGUF     | Эфф. bpw |
|----------------------|-----------|---------------|----------|-------------|-------------|----------|----------|
| Qwen2.5 3B Instruct  | 3.09B     | 5.75 GiB      | 5.76 GiB | 5.75 GiB    | 1.44 GiB    | 1.80 GiB | 5.00     |
| LFM2.5 1.2B Instruct | 1.17B     | 2.18 GiB      | 2.18 GiB | 2.18 GiB    | 0.54 GiB    | 0.68 GiB | 5.00     |
| LFM2.5 2.6B          | 2.70B     | 5.02 GiB      | 5.04 GiB | 5.02 GiB    | 1.26 GiB    | 1.56 GiB | 4.97     |
| Qwen2.5 Coder 3B     | 3.09B     | 5.75 GiB      | 5.76 GiB | 5.75 GiB    | 1.44 GiB    | 1.80 GiB | 5.00     |
| Qwen2.5 Coder 1.5B   | 1.54B     | 2.88 GiB      | 2.89 GiB | 2.88 GiB    | 0.72 GiB    | 0.92 GiB | 5.11     |
| GPT-2 XL             | 1.56B     | 5.99 GiB      | 5.99 GiB | 2.90 GiB    | 0.73 GiB    | 1.10 GiB | 6.07     |

| Модель               | Исключено элементов | Сжатие весов | Пик / VRAM |
|----------------------|---------------------|--------------|------------|
| Qwen2.5 3B Instruct  | 0                   | 3.20x        | 35.2%      |
| LFM2.5 1.2B Instruct | 0                   | 3.20x        | 14.7%      |
| LFM2.5 2.6B          | 0                   | 3.22x        | 29.7%      |
| Qwen2.5 Coder 3B     | 0                   | 3.20x        | 35.2%      |
| Qwen2.5 Coder 1.5B   | 0                   | 3.13x        | 19.7%      |
| GPT-2 XL             | 50 331 648          | 5.44x        | 25.1%      |

### Интерпретация

Формулы: FP16 = 2P байт; идеал 4-bit = округление P/2 байт вверх; effective bpw = 8S\_GGUF/P; сжатие = S\_исходных\_весов/S\_GGUF. Реальный GGUF хранит блоковые масштабы, метаданные и веса смешанной точности. Эти расчёты не измеряют VRAM или память обучения.

Compression ratio относится к original weight bytes относительно GGUF, как задано в расчётном файле; licenses/tokenizer/config входят в общий размер файлов вместе с весами.

GPT2-XL: запрошен рецепт Q4\_K\_M, но quantizer сообщил fallback для 144 из 580 тензоров из-за размеров блоков. Поэтому это смешанная точность, а не ровно 4 бита на каждый вес; 6.06 bpw в логе относится только к tensor payload, а effective GGUF bpw выше учитывает весь файл.

# Методика и происхождение данных

Suite: document-benchmark-v1 | 25 cases | SHA-256  
449930d24dc3bd18786b68a494302672c4658243b90887ab763db4e2360bf70c

Тесты используют фиксированный синтетический fixture: редактирование точного фрагмента, строгий JSON, извлечение таблиц, уточнение неоднозначного запроса, нативное планирование инструмента и follow-up по результату инструмента. Грейдинг детерминированный; LLM-as-judge не применяется.

Базовая Qwen3.5 модель исключена из этого набора по прямому запросу пользователя. Исторические диагностические отчёты, где она была активной baseline, не входят в текущий run; основной рейтинг включает только шесть pinned кандидатов.

## Правила отбора

Сначала проверяются полнота и совпадение ревизии, artifact SHA-256, quantization и suite SHA/count. Рейтинг: доля полностью пройденных cases по убыванию, затем native\_tool\_planning pass rate, меньший peak VRAM delta и меньшая медианная задержка. Второй вариант - наименьший GGUF среди меньших моделей в абсолютном диапазоне 10 п.п. от победителя; иначе второе место общего ранжирования.

## Конфигурация

GPT2-XL - базовая модель продолжения текста, а не instruction/chat-модель. Для неё использовался /v1/completions с контекстом 1 024; нативный chat tool-calling этой модели не свойственен. Баллы показывают пригодность для выбранной задачи, а не универсальное качество модели.

Каждый кандидат запускается локально через llama.cpp, один слот, 99 GPU layers, температура 0, seed 42, API loopback. VRAM снимается через nvidia-smi примерно каждую секунду; guard 5 500 MiB относится к общей памяти GPU. Harness использует context 8 192; candidate scores основаны на direct API report settings. В этой оценке документы оставались синтетическими, DOCX инструменты не вызывались.

## Источники модели и фиксация

| Модель               | Зафиксированный репозиторий / ревизия                                                        | Лицензия источника                                                                                         | Среда конвертации                                                                                                                 | SHA-256 GGUF                                                     |
|----------------------|----------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| Qwen2.5 3B Instruct  | <a href="#">Qwen/Qwen2.5-3B-Instruct</a><br>aa8e72537993ba99e69dfaafa59ed015b17504d1         | Qwen Research License: non-commercial research/evaluation; commercial use requires a separate license.     | Python 3.12.14<br>transformers 5.0.0 /<br>huggingface-hub 1.33.0 /<br>tokenizers 0.22.2 / torch<br>2.11.0<br>llama.cpp 1537a0a8b2 | f259d51e5e8b2bae0106831cb3398cdf85296f323ead191eebcb9c74a5c112   |
| LFM2.5 1.2B Instruct | <a href="#">LiquidAI/LFM2.5-1.2B-Instruct</a><br>0f604ada3f766f9f257460c4c9f0b5d6f69d431b    | LFM Open License v1.0: \$10M annual-revenue threshold applies; review the agreement for commercial rights. | Python 3.12.14<br>transformers 4.57.6 / torch<br>2.11.0<br>llama.cpp 1537a0a8b2                                                   | c46a48cde3298e1a31b4f4c78d5062c5a6bc6efdd510687295be5bbaa84a5d22 |
| LFM2.5 2.6B          | <a href="#">LiquidAI/LFM2.5-2.6B</a><br>654f9463ce32b05d0429d76fe1f580b27d4c1ac0             | LFM Open License v1.0: \$10M annual-revenue threshold applies; review the agreement for commercial rights. | Python 3.12.14<br>transformers 5.0.0 /<br>huggingface-hub 1.33.0 /<br>tokenizers 0.22.2 / torch<br>2.11.0<br>llama.cpp 1537a0a8b2 | feadc757b08e97a7cd50becabf3b7860923970dea4e7fee54bbad46e57bd30ce |
| Qwen2.5 Coder 3B     | <a href="#">Qwen/Qwen2.5-Coder-3B-Instruct</a><br>488639f1ff808d1d3d0ba301aef8c11461451ec5   | Qwen Research License: non-commercial research/evaluation; commercial use requires a separate license.     | Python 3.12.14<br>transformers 5.0.0 /<br>huggingface-hub 1.33.0 /<br>tokenizers 0.22.2 / torch<br>2.11.0<br>llama.cpp 1537a0a8b2 | 6d4402c3e6cd50f060a0ded8c9bfafd99dd2fb4be3dd078abd27c21409d585a9 |
| Qwen2.5 Coder 1.5B   | <a href="#">Qwen/Qwen2.5-Coder-1.5B-Instruct</a><br>2e1fd397ee46e1388853d2af2c993145b0f1098a | Apache License 2.0                                                                                         | Python 3.12.14<br>transformers 4.57.6 / torch<br>2.11.0<br>llama.cpp 1537a0a8b2                                                   | 66517fd66665622cb244156a41d99e86a4316840e8a82cc42ee9bc91b28a6018 |

| Модель   | Зафиксированный репозиторий / ревизия                                                | Лицензия источника | Среда конвертации                                                                                                                                                                                                                                                                                                   | SHA-256 GGUF                                                     |
|----------|--------------------------------------------------------------------------------------|--------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| GPT-2 XL | <a href="#">openai-community/gpt2-xl</a><br>15ea56dee5df4983c59b2538573817e1667135e2 | MIT license flag   | Python 3.12.14<br>transformers 5.0.0 /<br>huggingface-hub 1.33.0 /<br>tokenizers 0.22.2 / torch<br>2.11.0<br>llama.cpp 1537a0a8b2<br>scripts/convert-gpt2.py<br>SHA-256 5fe5c520e699a0b8c7acda0d0b5b11770c33ad02643e8f4cef6a9eadd425eb29;<br>deterministic attention masks<br>skipped, learned tensors<br>unchanged | 9d0685c33ba27d93a28d79ca653028af221b09c489e75f7b8c9f0e3e0da07583 |

Краткие флаги сверены с сохранёнными LICENSE/README файлами. Это не юридическое заключение; исходный текст конкретной ревизии определяет применимые условия. Hash относится к локальному GGUF-артефакту.

Исходники runtime: llama.cpp b11379. Никакой remote custom code не исполнялся.

Параметры benchmark

| Параметр           | Значение                                            |
|--------------------|-----------------------------------------------------|
| Видеокарта         | NVIDIA GeForce RTX 3050 6GB Laptop GPU              |
| Драйвер NVIDIA     | 616.56                                              |
| Видеопамять        | 6144 MiB                                            |
| Процессор          | 12th Gen Intel(R) Core(TM) i5-12450H                |
| ОЗУ                | 15.73 GiB                                           |
| Windows            | 10.0.26200                                          |
| ID запуска         | candidate-benchmark-2026-10-04-v1                   |
| Порт               | 127.0.0.1:8082                                      |
| Context            | Chat-кандидаты: 4 096; GPT2-XL: 1 024; Astra: 8 192 |
| GPU layers / slots | 99 / 1                                              |
| GPU identifier     | nvidia-smi --id=0                                   |
| Температура / seed | 0 / 42                                              |
| Ограничение VRAM   | 5 500 MiB общей памяти GPU                          |

Cleanup status


Recorded 2026-10-03T21:23:37.2945190Z: removed lfm2.5-2.6b (6.60 GiB), qwen2.5-coder-3b-instruct (7.56 GiB), qwen2.5-coder-1.5b-instruct (3.80 GiB), gpt2-xl (7.09 GiB); retained qwen2.5-3b-instruct, lfm2.5-1.2b-instruct.

# Проверка в самом Harness

Это отдельный smoke после выбора модели, а не часть рейтинга 25 случаев. Контекст увеличен до 8 192 для SDK. Настройки и системный prompt Harness отличаются от прямого сравнительного API.

| Проверка                      | Фактический результат                                                           |
|-------------------------------|---------------------------------------------------------------------------------|
| Модель / контекст             | Qwen2.5 3B Instruct / 8192                                                      |
| Первый API smoke              | Короткий ответ пройден; native tool call не получен; продолжение не запускалось |
| Второй API smoke              | Ответ и tool call пройдены; продолжение после результата не содержало ответа    |
| Запрос через UI               | Назови столицу Казахстана одним словом.                                         |
| Ожидалось / получено          | Астана / Алматы - проверка не пройдена                                          |
| VRAM в простое после проверки | 2305 MiB занято; 3697 MiB свободно                                              |
| Состояние продукта            | Подключён для исследования. DOCX-инструменты и дообучение отсутствуют           |

Оба неуспешных smoke сохранены, включая результаты до и после добавления диагностических полей. Этот раздел не скрывает ошибки победителя и не меняет зафиксированный рейтинг. Снимок VRAM - одна точка при контексте 8 192, не пик сравнительного теста.



Наблюдаемый ответ UI: Алматы. Выбранная модель видна в нижней панели. Исправлять тест подбором единственного удачного повторного ответа не стали.